Josafá de Pinho Souza

CIENTISTA DE IA | ARQUITETO DE APLICAÇÕES WEB & SOLUÇÕES RAG

📍 São Paulo – SP (Butantã) 📞 (11) 98107-9198 ✉️josafa.souza@gmail.com 🔗linkedin.com/in/josafa

💻github.com/Josafasouza

RESUMO PROFISSIONAL

Arquiteto de Aplicações Web e Cientista de IA com mais de 10 anos de trajetória no desenho e sustentação de sistemas críticos, especializado na engenharia de ponta a ponta de soluções baseadas em **IA Generativa, RAG em Produção e Arquiteturas Agênticas**. Experiência prática consolidada na orquestração de bancos vetoriais (FAISS, pgvector), depuração e integração avançada de pipelines em **Python (FastAPI)** e consumo resiliente de APIs LLM (OpenAI e Anthropic Claude). Ampla expertise em mitigação sistemática de alucinações (avaliação de *groundedness* e *faithfulness*), controle orçamentário de tokens e conformidade estrita com a LGPD em projetos para o setor público e financeiro.

COMPETÊNCIAS TÉCNICAS & DOMÍNIO DA FUNÇÃO

Engenharia de Prompt & Avaliação LLM
Técnicas Few-Shot, CoT, avaliação sistemática de saídas, mitigação de alucinação, *groundedness*, *faithfulness* e citação estrita de fontes.

RAG em Produção & Vector Stores
Estratégias de chunking semântico/hierárquico, re-ranking e busca vetorial densa com **FAISS**, pgvector e Redis Vector Store.

APIs LLM (OpenAI & Anthropic)
Integração avançada com streaming, controle de taxa/limites, gerenciamento de context window e governança estrita de custo/tokens.

Python, SQL & Microsserviços
Python (FastAPI, Flask) para depuração de pipelines de dados ponta a ponta; consultas SQL analíticas em PostgreSQL e SQL Server.

Arquiteturas Agênticas & Fine-Tuning
LangChain, LangGraph, CrewAI, Semantic Kernel; adaptação de modelos e instruction tuning / LoRA para contextos especializados.

DevOps, Cloud & Governança LGPD
Docker, Azure (Container Apps/AKS), AWS, GCP; mascaramento de dados sensíveis, conformidade LGPD e telemetria auditável.

EXPERIÊNCIA PROFISSIONAL RECENTE

Arquiteto de IA & Líder Técnico — **Guardian Engine / Zendesk AI Secure** 03/2026 – Presente

- Concepção e sustentação da arquitetura do microsserviço **Zendesk AI Secure API** em **Python (FastAPI)**, containerizado em **Docker** com roteamento dinâmico via Traefik para automação de triagem e resolutividade de chamados.
- Implementação de pipeline **RAG em produção** utilizando **FAISS** e Redis para recuperação precisa de manuais técnicos e bases corporativas, estabelecendo chunking contextualizado e técnicas dinâmicas de citação de fonte.
- Integração robusta com as APIs da **Anthropic (Claude 3.5 Sonnet)** e **OpenAI**, desenvolvendo middlewares para streaming de resposta, interceptação de PII (LGPD), failover e controle contínuo de custo de tokens.
- Desenvolvimento de suíte de testes de validação automática de qualidade de respostas, mensurando índices de *faithfulness* e *groundedness* com zero tolerância a alucinações de conformidade.

TRAJETÓRIA PROFISSIONAL EM ARQUITETURA & SETOR PÚBLICO

Especialista em Arquitetura de Software — **Fintech Startup** 09/2025 – Presente

- Atuação colaborativa em squad ágil multidisciplinar ao lado de times backend e frontend, projetando microsserviços em .NET 9 e Python de baixa latência hospedados no Azure.
- Construção de pipelines analíticos com **SQL avançado e PostgreSQL**, rastreando persistência de dados de transações e garantindo integridade e observabilidade de ponta a ponta.
- Automação de esteiras CI/CD com GitHub Actions e orquestração de contêineres Docker, reduzindo o tempo de implantação contínua em ambientes de auditoria regulatória.

Diretor de Tecnologia — **Prefeitura Municipal de Franco da Rocha** 01/2022 – 10/2024

- Liderança da estratégia e arquitetura de aplicações de missão crítica para o **setor público**, integrando bases cadastrais unificadas sob rigoroso padrão de **segurança e LGPD**.
- Coordenação direta de equipes multidisciplinares ágeis, promovendo a migração de serviços legados on-premise para nuvem com foco em estabilidade, auditoria de acesso e redução de custos.
- Definição de diretrizes de governança de dados governamentais e integração de APIs corporativas para atendimento a mais de 150 mil cidadãos.

Gerente de Projetos de TI & Qualidade — **Keeggo Tecnologia AS (Alocação Banco Santander)** 10/2001 – 11/2016

- Gestão técnica e arquitetura de sistemas bancários de alta criticidade, garantindo conformidade com normas regulatórias do BACEN e políticas de segurança bancária.
- Depuração de pipelines transacionais de dados via SQL/Stored Procedures, liderando testes integrados e squads de engenharia em regime formal de entrega contínua.

MAPEAMENTO DIRETO COM OS REQUISITOS DA VAGA

Requisito Obrigatório da Vaga	Evidência Prática & Entregas Realizadas	Stack Aplicada
Arquiteto Web (5+ anos)	Mais de 10 anos desenhando arquiteturas web escaláveis, microsserviços e APIs.	**Web Architecture**
RAG em Produção & FAISS	Bases corporativas indexadas com FAISS, chunking semântico e busca híbrida.	**FAISS / RAG**
APIs OpenAI & Anthropic	Integração via streaming, controle fino de taxa, tokens e context window.	**Claude / GPT-4o**
Mitigação de Alucinação	Avaliação de groundedness, faithfulness e exigência estrita de fontes.	**Eval / Guardrails**
Ambientes Regulados & LGPD	Liderança técnica no setor público (Prefeitura) e instituições financeiras.	**LGPD / Setor Público**

FORMAÇÃO ACADÊMICA & ESPECIALIZAÇÕES

🎓 **Pós-Graduação em Arquitetura de Software, Ciência de Dados e Cibersegurança**
Pontifícia Universidade Católica de Campinas (PUCCAMP) — Conclusão em 2025

🎓 **Graduação em Gestão da Tecnologia da Informação**
Faculdade São Judas Tadeu — Concluído em 2024

Aperfeiçoamento Contínuo: Arquiteturas Agênticas (LangGraph/CrewAI), Bancos Vetoriais e Embeddings, Governança de IA e LGPD.